

INSTITUTO TECNOLÓGICO DE LAS AMÉRICAS (ITLA)

Tarea 5: Investigación Académica

Codificación de Caracteres y Estructuras de Archivos de Datos

Estudiante: Eithan Colomé

Matrícula: 2026-0275

Asignatura: Programación para Mecatrónicos

Docente: Carlos Antonio Pichardo Viuque

Santo Domingo, República Dominicana
26 de junio de 2026

Investigación sobre Codificación de Caracteres y Tipos de Archivos

1. Investigación sobre Codificación de Caracteres

La codificación de caracteres es el método que permite traducir los caracteres de texto (letras, números y símbolos) a un formato binario estructurado para que los sistemas informáticos puedan almacenarlos, procesarlos y transmitirlos de manera correcta.

1.1 ASCII (American Standard Code for Information Interchange)

- **Definición:** Diseñado en 1963, es uno de los estándares históricos de codificación de caracteres más importantes y sirve como pilar para los sistemas modernos.
- **Funcionamiento:** Utiliza una longitud fija de **7 bits** por carácter, logrando representar un máximo de 128 caracteres únicos (con valores numéricos enteros del 0 al 127).
- **Contenido:** Incluye de manera nativa las letras del alfabeto inglés (tanto mayúsculas como minúsculas), los números del 0 al 9, signos de puntuación de base y códigos de control del sistema. Carece de soporte para caracteres acentuados, la letra "ñ" o alfabetos no occidentales.

1.2 UTF-8 (Unicode Transformation Format 8-bit)

- **Definición:** Es el sistema de codificación dominante en la web global en la actualidad. Se define como un formato de longitud variable y mantiene compatibilidad total hacia atrás con ASCII.
- **Funcionamiento:** Implementa una estructura flexible que emplea bloques que van desde **8 bits (1 byte)** hasta **32 bits (4 bytes)** por carácter, según los requerimientos del símbolo a representar.
- **Contenido:** Ofrece soporte completo para todo el espectro del estándar Unicode. Puede codificar de forma precisa cualquier carácter escrito en el mundo, notaciones matemáticas complejas, alfabetos históricos y emojis. Optimiza espacio debido a que los caracteres occidentales base ocupan únicamente 1 byte.

1.3 UTF-16 (Unicode Transformation Format 16-bit)

Nota de precisión técnica: En la solicitud original se hace referencia al término "UTF18", el cual no existe dentro de los estándares de arquitectura informática. La nomenclatura correcta y equivalente en el ecosistema Unicode corresponde a **UTF-16**.

- **Definición:** Formato de codificación Unicode de longitud variable adoptado de manera interna en las estructuras de sistemas operativos como Microsoft Windows, así como en los entornos de desarrollo Java y .NET.

- **Funcionamiento:** Utiliza de forma nativa bloques básicos de **16 bits (2 bytes)** para codificar la gran mayoría de caracteres de uso común, escalando a 4 bytes mediante el uso de pares subrogados para símbolos avanzados o poco frecuentes.
- **Diferencia clave:** A diferencia de UTF-8, donde los caracteres del idioma inglés y signos básicos se almacenan en 1 byte, en UTF-16 consumen obligatoriamente un mínimo de 2 bytes, aumentando el tamaño de los archivos de texto marcadamente occidentales.

2. Investigación sobre Tipos de Archivos

Los formatos de archivo estructurados se emplean para la ordenación, el almacenamiento y el intercambio ágil de bloques de datos entre plataformas e infraestructuras de software heterogéneas.

2.1 JSON (JavaScript Object Notation)

- **Definición:** Formato liviano diseñado exclusivamente para el intercambio de datos estructurados en formato de texto plano. Deriva del ecosistema JavaScript, pero se procesa de forma independiente al lenguaje de programación utilizado.
- **Propiedades:** Destaca por su alta legibilidad para el ser humano y su facilidad de parseo, análisis y generación automatizada por parte de los entornos de cómputo.
- **Estructura:** Está compuesto por colecciones de atributos indexados en pares de clave/valor (objetos) junto con listas indexadas secuencialmente (arreglos).

```
{
  "estudiante": {
    "nombre": "Alejandro Pérez",
    "id": 45892,
    "cursos": ["Programación I", "Bases de Datos"]
  }
}
```

2.2 XML (Extensible Markup Language)

- **Definición:** Lenguaje de marcado general impulsado por el World Wide Web Consortium (W3C), enfocado estrictamente en la preservación y el transporte seguro de información.
- **Propiedades:** No dispone de etiquetas preestablecidas (como ocurre en HTML). Es inherentemente auto-descriptivo, posibilitando a los arquitectos de software la estructuración de etiquetas personalizadas adaptadas al negocio.
- **Estructura:** Se rige por una jerarquía estricta organizada en forma de árbol y delimitada por etiquetas de apertura y cierre. Aunque ofrece mecanismos robustos de validación, resulta más pesado y redundante en comparación con JSON.

```
<estudiante>
  <nombre>Alejandro Pérez</nombre>
  <id>45892</id>
  <cursos>
    <curso>Programación I</curso>
    <curso>Bases de Datos</curso>
  </cursos>
</estudiante>
```

2.3 CSV (Comma-Separated Values)

Nota de precisión técnica: En la solicitud original se incluyó la sigla "CVS". El estándar tecnológico global dedicado al transporte de datos tabulares planos se denomina **CSV** (Valores Separados por Comas).

- **Definición:** Tipo de formato en texto plano simplificado que mapea y almacena colecciones de información en disposiciones estrictamente tabulares.
- **Propiedades:** Es reconocido como el estándar por excelencia para la exportación, migración e importación de registros entre motores de bases de datos y herramientas de hojas de cálculo industriales (tales como Microsoft Excel o Google Sheets).
- **Estructura:** Cada salto de línea en el archivo plano determina una fila completa de la tabla, mientras que las columnas internas se segmentan mediante un carácter delimitador específico, generalmente la coma (,) o el punto y coma (;).

```
id,nombre,curso
45892,Alejandro Pérez,Programación I
45893,María López,Bases de Datos
```